

BÁO CÁO TỔNG KẾT: GPU FINOPS & COST OPTIMIZATION LAB

Học viên: Lương Hoàng Anh

MSSV: 2A202600472

Ngày hoàn thành: 13/05/2026

1. Giới thiệu

- **Mục tiêu của bài lab:** Thực hành quản trị tài nguyên GPU theo nguyên tắc FinOps, tập trung vào việc tối ưu hóa chi phí huấn luyện mô hình học sâu (Deep Learning) mà không làm ảnh hưởng đến hiệu suất và tiến độ dự án.
- **Tổng quan về GPU FinOps:** GPU FinOps là sự kết hợp giữa kỹ thuật hệ thống và quản lý tài chính, giúp các nhóm AI/ML hiểu rõ chi phí (Visibility), tối ưu hóa tài nguyên (Optimization) và vận hành hiệu quả (Operations) trên các nền tảng hạ tầng GPU (Cloud hoặc On-premise).

2. Phân tích từng phần

Part 1-7: Phân tích kết quả từ mock cluster Hệ thống FinOps Gateway đã cung cấp cái nhìn chi tiết về cụm GPU mô phỏng: - **Cluster monitoring insights:** Theo dõi được 4 Node với các dòng T4, V100, A100. Nhận diện được các GPU Idle (như Node-01 lúc bắt đầu) để tránh lãng phí. - **Cost tracking observations:** Tổng chi phí platform ban đầu là ~\$1.19. Hệ thống giúp phân tách chi phí theo từng workload (như train-llm-004). - **Spot instance savings analysis:** Sử dụng Spot cho phép tiết kiệm tới **70%** cho GPU T4 và **42.7%** cho A100. Tổng tiết kiệm được **\$1.29** chỉ trong vài phút mô phỏng. - **Autoscaling behavior:** Chính sách Scale-up (70%) và Scale-down (25%) giúp duy trì hiệu suất cụm ở mức tối ưu, tự động thu hồi tài nguyên khi nhu cầu giảm. - **Waste analysis và recommendations:** Tỷ lệ lãng phí (Waste) đo được là **23.2%**. Khuyến nghị ưu tiên chuyển đổi các job không khẩn cấp sang Spot Instance và tắt các node nhàn rỗi vào khung giờ thấp điểm.

Part 8: Phân tích real GPU training Thực hiện huấn luyện ResNet-18 thực tế trên GPU được detect (T4): - **FP32 vs Mixed Precision (AMP) comparison:** - FP32 (Baseline): Thời gian chạy ~120s/epoch. - AMP: Thời gian chạy ~85s/epoch (**Speedup ~29%**). - **Cost savings achieved:** Nhờ AMP chạy nhanh hơn và kết hợp cơ chế Spot giá lập, chi phí giảm từ **\$0.0117** xuống còn **\$0.0017** (Tiết kiệm ~85%). - **GPU utilization patterns:** Sử dụng AMP giúp giảm tải bộ nhớ GPU (Memory Footprint), cho phép tăng throughput mà không gây lỗi Out-of-Memory (OOM).

Part 8.5: Advanced analysis

- **Multi-GPU scaling efficiency:** Phân tích cho thấy việc scale từ 1 lên 8 GPU đạt hiệu suất ~85% do overhead giao tiếp (Inter-GPU communication). Điểm tối ưu chi phí nằm ở cấu hình 4 GPU A100 cho dự án lớn.
- **Project cost forecasting:** Dự báo ngân sách dựa trên burn-rate cho thấy với chiến lược tối ưu, dự án Fine-tuning LLM sẽ hoàn thành dưới mức budget \$5,000 (dự kiến còn dư ~\$1,150).
- **Optimization strategy prioritization:** Xếp hạng chiến lược cho thấy AMP và Spot Instance mang lại giá trị cao nhất với rủi ro thấp nhất (Low effort, High saving).

3. Kết luận và học hỏi

- **Những kỹ năng FinOps đã học:** Biết cách kết nối với Gateway giám sát chi phí, sử dụng API để lấy metric GPU thời gian thực và triển khai các hàm phân tích dự báo tài chính.
- **Các chiến lược cost optimization hiệu quả:** Tự động hóa việc chọn loại GPU (Right-sizing), tận dụng tối đa Spot Instance và Mixed Precision Training.
- **Ứng dụng thực tế trong projects:** Có thể áp dụng ngay vào các dự án Deep Learning tại doanh nghiệp để cắt giảm chi phí Cloud (AWS/GCP/Azure), đặc biệt là trong giai đoạn nghiên cứu (R&D) và thử nghiệm mô hình.

Người viết báo cáo: Lương Hoàng Anh